

Automatische transformatie van ingescande medicatieschema's naar gestructureerde digitale data: een proof-of-concept

Onderzoeksvoorstel Bachelorproef 2019-2020

Milad Nazari¹

Samenvatting

Het manueel aanmaken, ingeven en persisteren van digitale medicatiedata op basis van papieren medicatieschema's met uiteenlopend lay-outs is een tijdrovend en kostelijk proces, zeker wanneer het aantal te transformeren documenten groot is. In deze bachelorproef wordt er onderzocht naar een nauwkeurig digitalisatiesysteem die ingescande medicatieschema's automatisch transformeert naar gestructureerde data voor medicatielogistiek; eveneens wordt een proof-of-concept geïmplementeerd. Er wordt verwacht dat de documenten succesvol getransformeerd zullen worden, mits het implementeren van correctie- en optimalisatiealgoritmen om respectievelijk de nauwkeurigheid en performantie van het systeem te verbeteren, wat essentieel is voor IT-bedrijven.

Sleutelwoorden

Documentanalyse en -herkenning (DAR). Medicatieschema — Machineleertechnieken — OCR

Co-promotor

Bram Vandewalle² (Into Care by Pridiktiv NV)

Contact: ¹ contact@miladnazari.be; ² bram.vandewalle@into.care.be;

Inhoudsopgave

1	Introductie	1
2	State-of-the-art	2
3	Methodologie	2
4	Verwachte resultaten	2
5	Verwachte conclusies	2
	Referenties	2

1. Introductie

Het medicatieschema is een geheel van gestandaardiseerde informatie over de actieve medicatie van een patiënt, met inbegrip van de identiteit van de geneesmiddelen, hun dosering, indicatie, relevante gebruiksaanwijzingen en bijkomende informatie waar nodig. Het omvat zowel voorgeschreven als niet-voorgeschreven geneesmiddelen en voedingssupplementen.

Deze oplijsting van de actieve medicatie van de patiënt is niet enkel een essentieel hulpmiddel voor de patiënt bij de correct inname van medicatie maar ook voor medische professionals om bv. over- of onderdosering, dubbelmedicatie, en andere geneesmiddelgebonden problemen te voorkomen. Ook wordt het gebruikt bij de communicatie tussen zorgverstrekkers. Het medicatieschema wordt eveneens door verpleegsters geraadpleegd voor het klaarzetten van de medicatie.

Dit schema wordt grafisch steeds in tabulaire vorm gepresenteerd. Echter is de lay-out hiervan niet gestandaardiseerd; afhankelijk van de apotheker of andere zorgverstrekker worden andere kolomnamen, kolomverdeling, rand- en verdeelingsstijl, celgrootte en andere tabelelementen aangewend. Dit bemoeilijkt ernstig het ontwikkelen van een transformatiesysteem die ingescande medicatieschema's omzet in instanties van een uniform digitale datastructuur in bv. XML- of JSON-formaat voor digitale verwerking van de medicatiedata in gezondheidszorgplatformen.

Hierdoor is er een nood aan een digitalisatiesysteem die medicatieschema's van verschillende vormen en met verschillende lay-outs nauwkeurig omzet in corresponderende instanties van een uniforme datastructuurschema. De doelstelling van dit onderzoek is het bestuderen van de mogelijkheden om een dergelijk systeem tot stand te brengen en het implementeren van een proof-of-concept van een optimale oplossing. De volgende onderzoeksvragen kunnen gesteld worden bij dit onderzoek:

- Wat zijn de structuren en de relaties tussen de entiteiten in tabulaire data?
- Wat zijn de uitdagingen en complicaties bij tabelherkenning en -analyse? Kan er meer complexiteit ondervonden worden bij medicatieschematabellen?
- Hoe kan de correctheid en nauwkeurigheid van de transformatie van een tabel geëvalueerd worden?
- Welke oplossingen bestaan er reeds voor tabelherkenning en/of tabelanalyse?

- Wat is de optimale oplossing voor medicatieschema's? Hoe kan deze bepaald worden?
- Hoe kan domeinkennis gebruikt worden om de oplossing te optimaliseren?

2. State-of-the-art

Verskillende oplossingen voor tabeldetectie zijn reeds beschikbaar:

- Vervormbare convolutionele neurale netwerken (Siddiqui, Malik, Agne, Dengel & Ahmed, 2018)
- Verticale en horizontale lijndetectie (Gatos, Danatsas, Pratikakis & Perantonis, 2005)
- Naïve Bayes en documentstructuur (Li, Tang, Song & Xu, 2006)

Ook voor tabelanalyse zijn enkele oplossingen voorgesteld:

- Cellsegmentatie (Nazemi, Murray, Fernaando & McMeekin, 2016)
- Fast CNN (Oliveira & Viana, 2017)
- Faster R-CNN (Schreiber, Agne, Wolf, Dengel & Ahmed, 2017)
- Graafgebaseerde neurale netwerken (GNN's) (Qasim, Mahmood & Shafait, 2019)

3. Methodologie

Het uitvoeren van het onderzoek zal beginnen met het ontwerpen van een scoresysteem, ook wel een benchmarksysteem genoemd, waarbij de nauwkeurigheid, precisie, performantie en andere factoren van de tabelherkenningsoplossingen in rekening gebracht zullen worden. Hiervoor zullen reeds bestaande geannoteerde, geanonimiseerde medicatieschemadatasets gebruikt worden.

Hierna zullen de verschillende oplossingen geïmplementeerd en tevens geëvalueerd worden a.d.h.v. de benchmarksysteem. De optimale oplossing zal op deze manier bepaald worden.

Verder zullen potentiële optimalisatieopportuniteiten bestudeerd worden, deze zullen al dan niet domeinkennisgebonden zijn.

4. Verwachte resultaten

Enerzijds bestaan er in tabellen relaties tussen kolommen en cellen, en relaties tussen cellen onderling die voorgesteld kunnen worden door grafen en anderzijds vertonen de verschillende lay-outs van tabellen een patroon die door het menselijke brein maar dus ook door diepe neurale netwerken zeer snel herkend kan worden. Er wordt daarom verwacht dat een graafgebaseerde Deep Learning-oplossing de best resultaten zal opleveren.

5. Verwachte conclusies

Aangezien zowel nieuwe state-of-the-art algoritmen als reeds bestaande softwareimplementatieoplossingen beschikbaar, wordt er verwacht dat een performante proof-of-concept

van een digitalisatiesysteem voor medicatiesystemen succesvol gecreëerd zal worden. Eveneens wordt er verwacht dat domeinkennis de nauwkeurigheid van het systeem zal verhogen.

Referenties

- Gatos, B., Danatsas, D., Pratikakis, I. & Perantonis, S. (2005). Automatic Table Detection in Document Images. (Deel 3686, pp. 609–618). doi:10.1007/11551188_67
- Li, J., Tang, J., Song, Q. & Xu, P. (2006). Table Detection from Plain Text Using Machine Learning and Document Structure. In X. Zhou, J. Li, H. T. Shen, M. Kitsuregawa & Y. Zhang (Red.), *Frontiers of WWW Research and Development - APWeb 2006* (pp. 818–823). Berlin, Heidelberg: Springer Berlin Heidelberg.
- Nazemi, A., Murray, I., Fernaando, C. & McMeekin, D. A. (2016). Converting Optically Scanned Regular or Irregular Tables to a Standardised Markup Format to Be Accessible to Vision-Impaired. *World Journal of Education*, 6(5), p9–19. Verkregen 2019, van <https://eric.ed.gov/?id=EJ1158245>
- Oliveira, D. A. B. & Viana, M. P. (2017). Fast CNN-Based Document Layout Analysis. In *2017 IEEE International Conference on Computer Vision Workshops (ICCVW)* (pp. 1173–1180). doi:10.1109/ICCVW.2017.142
- Qasim, S. R., Mahmood, H. & Shafait, F. (2019). *Rethinking Table Recognition using Graph Neural Networks*.
- Schreiber, S., Agne, S., Wolf, I., Dengel, A. & Ahmed, S. (2017). DeepDeSRT: Deep Learning for Detection and Structure Recognition of Tables in Document Images. In *2017 14th IAPR International Conference on Document Analysis and Recognition (ICDAR)* (Deel 01, pp. 1162–1167). doi:10.1109/ICDAR.2017.192
- Siddiqui, S., Malik, M. I., Agne, S., Dengel, A. & Ahmed, S. (2018). DeCNT: Deep Deformable CNN for Table Detection. *IEEE Access*, PP, 1–1. doi:10.1109/ACCESS.2018.2880211